Actividad de exposición

Capítulo 5: *The Bias–Complexity Trade-off*

Curso de Teoría de la Generalización

Basado en *Understanding Machine Learning: From Theory to Algorithms*

Propósito de la actividad. Cada grupo deberá preparar y exponer uno de los temas asignados del Capítulo 5. La presentación debe desarrollar el contenido desde un punto de vista **conceptual, teórico y demostrativo**: no es suficiente mostrar fórmulas o resultados finales; se debe explicar qué problema se estudia, cuál es la estrategia de la demostración, por qué cada paso es válido y cómo se interpreta el resultado. Además, cada grupo deberá preparar una **aplicación en Python** que permita visualizar, simular o estudiar de manera concreta el fenómeno teórico correspondiente. La parte computacional debe complementar la teoría y no reemplazarla.

Temas y ejercicios a exponer

1. Sección 5.1 — The No-Free-Lunch Theorem

- Explicar la motivación y el significado del teorema dentro de la teoría del aprendizaje.
- Presentar el enunciado formal y desarrollar su demostración de manera organizada, justificando los pasos relevantes.
- Explicar qué enseña el resultado acerca de la necesidad de incorporar un sesgo inductivo o conocimiento previo al problema de aprendizaje.
- Relacionar el resultado con la elección de una clase de hipótesis y con las limitaciones de un algoritmo de aprendizaje universal.
- **Aplicación en Python:** construir una simulación sencilla sobre un dominio finito que permita ilustrar que un algoritmo puede desempeñarse bien para ciertos etiquetados y mal para otros cuando no se impone una estructura previa. La simulación debe ser interpretada a la luz del teorema.

2. Sección 5.2 — Error Decomposition

- Explicar la descomposición del error desarrollada en la sección y el papel que cumple cada término.
- Describir e interpretar el *approximation error* y el *estimation error*.
- Explicar cómo cambia cada componente cuando se modifica la complejidad de la clase de hipótesis $\mathcal{H}$.
- Relacionar formalmente esta descomposición con el *bias–complexity trade-off*.
- **Aplicación en Python:** comparar, sobre un conjunto de datos sintético o controlado, clases de hipótesis con distinta complejidad y estudiar cómo cambia el comportamiento de entrenamiento y generalización. La aplicación debe incluir una interpretación teórica de los resultados observados.

3. Ejercicio 1 — Sección 5.5

1. Prove that Equation (5.2) suffices for showing that

$$\mathbb{P}[L_{\mathcal{D}}(A(S)) \geq 1/8] \geq 1/7.$$

Hint: Let θ be a random variable that receives values in $[0, 1]$ and whose expectation satisfies $\mathbb{E}[\theta] \geq 1/4$. Use Lemma B.1 to show that $\mathbb{P}[\theta \geq 1/8] \geq 1/7$.

Indicaciones para la exposición (añadidas para esta actividad):

- reconstruir la relación entre la Ecuación (5.2) y la variable aleatoria θ propuesta en la pista;
- explicar por qué la información sobre $\mathbb{E}[\theta]$ permite obtener una cota para $\mathbb{P}[\theta \geq 1/8]$;
- justificar cuidadosamente el uso del Lema B.1 y concluir la desigualdad solicitada;
- **Aplicación en Python:** proponer una simulación de variables aleatorias acotadas en $[0, 1]$ que permita ilustrar la relación entre esperanza y probabilidad del evento de interés. La simulación debe ser interpretada como ilustración y no como sustituto de la demostración.

4. Ejercicio 2 — Sección 5.5

2. Assume you are asked to design a learning algorithm to predict whether patients are going to suffer a heart attack. Relevant patient features the algorithm may have access to include blood pressure (BP), body-mass index (BMI), age (A), level of physical activity (P), and income (I).
You have to choose between two algorithms; the first picks an axis aligned rectangle in the two dimensional space spanned by the features BP and BMI and the other picks an axis aligned rectangle in the five dimensional space spanned by all the preceding features.

1. Explain the pros and cons of each choice.
2. Explain how the number of available labeled training samples will affect your choice.

Indicaciones para la exposición (añadidas para esta actividad):

- comparar las dos clases de hipótesis desde el punto de vista de capacidad de representación y complejidad;
- explicar cómo el tamaño de la muestra etiquetada modifica la conveniencia de utilizar una clase más simple o una más compleja;
- relacionar la discusión con el *bias–complexity trade-off* desarrollado en el capítulo;
- mantener el análisis en el plano del aprendizaje estadístico, sin extraer conclusiones clínicas;
- **Aplicación en Python:** construir un conjunto de datos sintético y comparar el comportamiento de una clase de rectángulos en dos dimensiones con una alternativa más compleja al variar el tamaño de la muestra. Interpretar los resultados desde la teoría.

5. Ejercicio 3 — Sección 5.5

3. Prove that if $|\mathcal{X}| \geq km$ for a positive integer $k \geq 2$, then we can replace the lower bound of $1/4$ in the No-Free-Lunch theorem with

$$\frac{k-1}{2k} = \frac{1}{2} - \frac{1}{2k}.$$

Namely, let A be a learning algorithm for the task of binary classification. Let m be any number smaller than $|\mathcal{X}|/k$, representing a training set size. Then, there exists a distribution $\mathcal{D}$ over $\mathcal{X} \times \{0,1\}$ such that:

- There exists a function $f : \mathcal{X} \to \{0,1\}$ with $L_{\mathcal{D}}(f) = 0$.
- $\mathbb{E}_{S\sim\mathcal{D}^m}[L_{\mathcal{D}}(A(S))] \geq \frac{1}{2} - \frac{1}{2k}$.

Indicaciones para la exposición (añadidas para esta actividad):

- identificar qué parte de la demostración original del No-Free-Lunch debe ajustarse al reemplazar la relación entre $|\mathcal{X}|$ y m;
- desarrollar la nueva cota paso a paso y explicar de dónde aparece el factor k;
- interpretar el comportamiento de $\frac{1}{2} - \frac{1}{2k}$ cuando k aumenta;
- explicar qué enseña el resultado acerca de la relación entre el tamaño del dominio y el tamaño de la muestra;
- **Aplicación en Python:** realizar una simulación sobre dominios finitos para distintos valores de k y comparar la tendencia empírica con la cota teórica, aclarando que la simulación no reemplaza la demostración.

Lineamientos para la exposición

La aplicación en Python no sustituye la demostración. El código debe utilizarse como una herramienta para visualizar, experimentar o interpretar el resultado teórico. Cada gráfica, tabla o simulación presentada debe responder una pregunta concreta y debe ser explicada en términos de los conceptos del capítulo.

Cada exposición deberá evidenciar los siguientes componentes:

1. **Contexto y objetivo:** explicar claramente qué pregunta teórica se quiere responder.
2. **Desarrollo matemático:** presentar definiciones, resultados y demostraciones en un orden lógico, explicando la razón de los pasos importantes.
3. **Interpretación:** indicar qué significa el resultado y qué limitaciones tiene.
4. **Aplicación en Python:** incluir código propio, resultados reproducibles y una interpretación conectada con la teoría.

5. **Cierre:** resumir la idea central que debería quedar después de la exposición.

Rúbrica de evaluación

La actividad se calificará sobre **50 puntos**. Los criterios priorizan la comprensión teórica y la capacidad de explicar el razonamiento matemático; el código por sí solo no constituye evidencia suficiente de comprensión.

Criterio	Puntos	Qué se evalúa
Dominio teórico y conceptual	15	Comprensión de definiciones, teoremas, supuestos, alcance e interpretación del tema asignado. Uso correcto de la notación y del lenguaje matemático.
Desarrollo demostrativo y argumentación	15	Organización lógica de la demostración o solución, justificación de los pasos, conexión entre resultados previos y conclusión, y capacidad para explicar por qué funciona el argumento.
Aplicación en Python	10	Pertinencia de la simulación o experimento, corrección del código, reproducibilidad y capacidad de la aplicación para ilustrar el fenómeno teórico estudiado.
Interpretación y conexión teoría–aplicación	5	Capacidad para relacionar los resultados computacionales con la teoría, reconocer limitaciones y evitar conclusiones que la simulación no permite justificar.
Comunicación y calidad de la exposición	5	Claridad, organización, manejo del tiempo, legibilidad del material, participación del grupo y capacidad para responder preguntas sobre el trabajo presentado.
Total	**50**	

Criterio general de la actividad. Se valorará especialmente que el grupo pueda explicar *por qué* funciona cada argumento y no únicamente reproducir una demostración o ejecutar un programa. Durante la exposición se podrán realizar preguntas a cualquiera de los integrantes para verificar la comprensión del trabajo presentado.

Referencia: Shalev-Shwartz, S. y Ben-David, S. (2014). *Understanding Machine Learning: From Theory to Algorithms*. Cambridge University Press.

Descriptores de desempeño

Criterio	Excelente	Avanzado	Progresivo	Inicial	Nulo / insuficiente
Dominio teórico y conceptual	Explica con precisión los conceptos, supuestos y alcance; utiliza correctamente la notación y establece conexiones pertinentes.	Presenta una comprensión sólida, con imprecisiones menores que no afectan la idea central.	Comprende los elementos principales, pero presenta vacíos o confusiones parciales.	La explicación es fragmentaria y muestra dificultades importantes en conceptos o notación.	No evidencia comprensión del contenido o presenta errores conceptuales fundamentales.
Desarrollo demostrativo y argumentación	Reconstruye la demostración o solución con una estrategia clara; justifica los pasos relevantes y puede defenderlos ante preguntas.	El argumento es correcto y organizado, aunque algunos pasos reciben una justificación limitada.	La solución alcanza buena parte del resultado, pero omite o debilita pasos importantes.	Presenta procedimientos aislados, saltos lógicos o una demostración incompleta.	No desarrolla una demostración válida o se limita a mostrar el resultado final sin argumentación.
Aplicación en Python	La aplicación es correcta, reproducible y diseñada para ilustrar directamente el resultado teórico; las decisiones de implementación están justificadas.	La aplicación funciona y es pertinente, con detalles menores de diseño o explicación por mejorar.	El código funciona parcialmente o la conexión con el objetivo teórico es limitada.	La aplicación es superficial, poco reproducible o se reduce a ejecutar código sin propósito claro.	No presenta aplicación funcional o el código no guarda relación con el tema asignado.
Interpretación y conexión teoría–aplicación	Interpreta correctamente los resultados, los vincula con la teoría y distingue con claridad evidencia empírica de demostración matemática.	La interpretación es adecuada, con alguna limitación menor en la conexión teoría–experimento.	Presenta una interpretación general, pero con conexiones débiles o afirmaciones poco justificadas.	Describe resultados sin analizarlos o confunde evidencia computacional con demostración.	No interpreta los resultados o extrae conclusiones incompatibles con la teoría.
Comunicación y calidad de la exposición	Presentación clara, ordenada y profesional; participación equilibrada y respuestas precisas a las preguntas.	Comunicación clara en general, con problemas menores de organización o profundidad en las respuestas.	La exposición es comprensible, pero depende excesivamente de lectura, diapositivas o código.	Presentación desorganizada, difícil de seguir o con participación muy desigual.	No logra comunicar el trabajo o no puede responder preguntas básicas sobre lo presentado.